

NasalMpro · ALBOMB

Mpro 표적 비강 항바이러스 후보 발굴 + 자율 에이전트 AI

제4회 AI 신약개발 경진대회 (4th JUMP AI) 기술 보고서

팀: 아시아경제교육센터 알파폴드팀 (팀장 국경희)

멘토: 홍성현 ((주)클리캠바이오 대표이사)

주최 보건복지부 · 주관 한국보건산업진흥원(KHIDI)

라이브 데모: <https://mpro.wnffn62.workers.dev>

오프라인 PWA · 엣지 상시 호스팅 (PC 전원과 무관)

목차

1. 개요 및 프로젝트 방향 전환

본 프로젝트는 SARS-CoV-2의 Main Protease(3CLpro, 이하 Mpro)를 표적하는 저해제 후보를 계산으로 선별하고, 이를 비강 스프레이 형태의 국소 항바이러스제 관점에서 평가·최적화하는 자율 에이전트 AI 시스템이다.

1.1 초기 방향과 기술적 한계

초기에는 AlphaFold3로 항체-항원 결합 복합체를 예측하려 하였으나, 약 한 달간 seed 수를 높여가며 반복했음에도 항체-항원 복합체 예측 정확도가 다른 복합체 유형 대비 현저히 낮은 구조적 한계를 확인하였다.

1.2 전환된 접근

‘코로나바이러스’ 테마는 유지하되, 타겟을 스파이크 단백질에서 **Mpro를 표적하는 리간드/저해제 결합 예측**으로 전환하였다. 응용 전망 또한 알부민 중심 접근에서 **비강 스프레이 국소 전달 전략**으로 조정하였다. Mpro는 바이러스 폴리단백질 절단에 필수적이며 인간 프로테아제와 상동성이 낮아 선택적 항바이러스 표적으로 검증된 부위이다(Nirmatrelvir, Ensitrelvir 등 승인·임상 저해제 존재).

2. 데이터셋

공개 실측 활성 데이터를 통합하여 학습·검증에 사용하였다. 모든 화합물은 실측 pIC50(= $-\log_{10} IC_{50}[M]$)을 보유한다.

출처	화합물 수	설명
ChEMBL (ChEMBL4523582)	4,415	SARS-CoV-2 Mpro 저해 활성 assay
COVID Moonshot	1,944	오픈사이언스 신규 합성·측정 데이터
ChEMBL + Moonshot 중복	9	두 출처 공통
통합 (고유)	6,368	학습·검증 전체

유사도 기준물질로는 실측 강활성 상위 100종을 사용하였다. 데이터는 활성/개발성 지표가 사전 계산된 형태로 앱에 내장되며, 상위 400종은 웹 라이브러리 탐색 UI로 제공된다.

3. 방법론

3.1 QSAR 활성 예측 모델

기존 접근은 기준물질과의 Morgan fingerprint Tanimoto 유사도라는 단순 휴리스틱(Spearman $\rho \approx 0.34$)에 의존했다. 본 시스템은 이를 넘어 **6,368종 실측 pIC50으로 학습한 QSAR 회귀 모델**을 도입한다.

- 특징(feature): Morgan fingerprint (radius=2, 2048 bit) + 7개 물성(MW, logP, TPSA, HBD, HBA, RotB, QED) 표준화. 총 2,055차원.
- 모델 A — RandomForest (서버/로컬 Streamlit): 고정밀 예측용.
- 모델 B — Ridge 선형 (브라우저): 가중치를 JSON으로 export하여 오프라인 브라우저에서 임의 SMILES를 실시간 예측(RDKit-WASM으로 지문 계산 후 내적).

3.2 검증 — Scaffold 기반 교차검증

활성 데이터에는 서로 유사한 아날로그가 많아, 무작위 분할은 학습/평가 세트에 near-duplicate가 섞여 성능을 과대평가한다. 이를 방지하기 위해 **Murcko 골격(generic scaffold) 단위 5-fold GroupKFold** 교차검증을 사용하였다(1,960개 고유 골격). 아래 지표는 학습에 쓰이지 않은 분자에 대한 out-of-fold 예측 기준의 정직한 일반화 성능이다.




그림 1. 모델 검증 뷰 — 예측 pIC50 vs 실측 pIC50 (out-of-fold). 대각선에 가까울수록 정확.

3.3 자율 에이전트 파이프라인

대회 테마인 ‘신약개발 단계별 특화 에이전틱 AI’에 맞춰, 시드 분자를 입력하면 4개 에이전트가 순차 실행되는 파이프라인을 구현하였다. 전 과정이 브라우저에서 오프라인으로 재현된다.

에이전트	역할	도구·방법
Agent 1	가설 생성	Mpro 표적 근거·목적함수 정의(활성·비강·SAR)
Agent 2	활성·물성 평가	QSAR 예측 pIC50 + 유사도 + Lipinski/Veber
Agent 3	분자 최적화 루프	실측 라이브러리 아날로그 검색 + ML 스코어 hill-climb 재앵커
Agent 4	규제·제형 판정	구조알림 스캔 + 비강 전달성·비임상 판정

Agent 3의 최적화 효용은 $U = 0.60 \cdot \text{정규화 예측활성} + 0.25 \cdot \text{비강전달성} + 0.15 \cdot \text{SAR 연속성}$ 으로 정의된다. 매 라운드 현재 앵커의 아날로그(지문 유사도 ≥ 0.15) 중 효용 최대 후보로 재앵커하며, 개선이 없으면 수렴한다.

자율 에이전트 · 리드 최적화 파이프라인

시드 분자를 입력하면 4개 에이전트가 순차적으로 가설수립 → 활성평가(QSAR 도구) → 도구기반 분자 최적화 루프 → 규제-제형 판정을 수행합니다. 제4회 JUMP AI 4개 영역을 그대로 구현한 오픈소스 에이전트 파이프라인입니다.

CC(C)[C@@H](C(=O)N[C@@H](CC1CCNC1=O)C(O)S(=O)(=O)[O-])NC(=O)OCC2=CC=CC=C2.[Na+]

자율 최적화 실행

GC376 시드

Nirmatrelvir 시드

악한 리드(Aspirin) 시드

1 Agent 1 · 가설 생성

추론

타겟: SARS-CoV-2 Main Protease(3CLpro, Mpro) — 바이러스 폴리단백질 절단 필수 효소.

목적함수: 예측 pIC50 최대화 & t. 비강 전달성·약물성 유지 (효용 U = 0.60·활성 + 0.25·비강 + 0.15·SAR연속성).

시드 진단: 예측 pIC50 6.93 (중등도), 비강 27.3. 활성 향상 여지 큼 — 아날로그 탐색으로 최적화.

2 Agent 2 · 활성·물성 평가

tool - QSAR

예측 pIC50 (Ridge QSAR)	6.934
강활성 100종 최대 유사도	0.598
MW / logP / TPSA	507.5 / -2.79 / 174.0
Lipinski / Veber	미통과 / 미통과

도구: 6,368종 실험 pIC50 학습 QSAR (scaffold-CV p=0.76). 실험 라이브러리에서 지문 유사도 기반 검색.

3 Agent 3 · 도구기반 분자 최적화 루프

tool - 아날로그검색+ML

시드에서 출발해 매 라운드 실험 라이브러리의 아날로그(지문 유사도≥0.15) 중 효용 최대 후보로 재영커하는 hill-climb. 2회 개선 후 수렴.

R	후보	예측 pIC50	측정 pIC50	비강	SAR유사도	효용 U
0	시드	6.93	—	27.3	1.000	0.470
1	CHEMBL5563513	8.15	8.00	90.2	0.299	0.626
2	CHEMBL5565858	7.94	7.82	87.8	0.939	0.698

측정 pIC50은 에이전트가 사용하지 않은 검증용 실험값 — ML 예측이 실제 강활성 후보로 수렴했는지 확인용.

4 Agent 4 · 규제-제형 판정

rule-based

최종 후보 구조알림: 주요 반용성/독성 구조알림 없음

비강 제형 판정: 비강 전달성 87.8/100 → 유리(점막 투과·체류 양호 추정).

출력은 계산 기반 후보 선별 자료입니다. 독성 ADME-제형 안정성·세포/동물/임상 검증 전 효능 주장 불가.

최종 추천 후보 · CHEMBL5565858

예측 pIC50 7.94 측정 pIC50 7.82 비강 87.8 활성 향상 +1.01

시드(예측 6.93) → 자율 탐색으로 예측 pIC50 7.94 후보 도출. 측정값 7.82가 강활성을 확인.

그림 2. 자율 에이전트 파이프라인 실행 결과 (4개 에이전트 + 최적화 트레이스 + 최종 추천).

4. 결과

4.1 모델 성능 (scaffold-CV)

모델	Spearman ρ	R^2	RMSE
RandomForest (서버)	0.809	0.643	0.727
Ridge 선형 (브라우저)	0.755	0.536	0.828
유사도 베이스라인(기준)	0.338	—	—

QSAR 모델은 기존 유사도 대비 순위상관을 ρ 0.34 → 0.81(RF) / 0.76(Ridge)로 약 2.4배 향상시켰으며, 이는 골격 분할 기준의 보수적(정직한) 지표이다.

4.2 자율 최적화 사례

GC376(공유결합형 Mpro 저해제)을 시드로 자율 최적화를 실행한 결과, 예측 pIC50 **6.93** → **7.94**의 아날로그를 2라운드 만에 도출하였다. 트레이스에 함께 표기되는 측정 pIC50(에이전트가 사용하지 않은 검증값)은 도출 후보가 실제 강활성 영역으로 수렴했음을 확인해 준다.

4.3 단일 분자 실시간 평가

임의 SMILES 입력 시 브라우저에서 예측 pIC50(추정 IC50 nM 환산), 개발성 Composite, 비강 전달성, 강활성 유사도, 약물성 지표를 즉시 산출한다.



그림 3. 단일 분자 평가 - 예측 pIC50을 헤드라인으로, 물성·유사도·구조를 함께 제시.

5. 시스템 및 배포

- 구현: 단일 정적 PWA(RDKit MinimalLib WebAssembly) — 서버·빌드 없이 브라우저에서 실행.
- 오프라인: Service Worker가 앱 셀·모델·라이브러리·WASM을 프리캐시(최초 1회 온라인 후 오프라인 동작).
- 배포: Cloudflare Worker 엣지 상시 호스팅 – 개발 PC 전원과 무관하게 접속 가능. 고정 주소 <https://mpro.wnffn62.workers.dev>
- 로컬 no-code 도구: Streamlit + 실제 RDKit/RandomForest(더블클릭 실행) 병행 제공.

5.1 대회 4개 영역 매핑

대회 영역	본 시스템의 구현
자율 가설생성·검증	Agent 1 가설 + Agent 2 QSAR 활성 검증
도구기반 분자 최적화 루프	Agent 3 아날로그 검색·ML 스코어 hill-climb
규제·지능형 임상 설계	Agent 4 구조알림·비임상·PK/PD 판정
융합	비강 제형 설계 + 통합 파이프라인 + ALBOMB 연계

6. 연계 플랫폼 — ALBOMB (당화알부민 tPDC)

클리켄바이오의 원천기술인 **클릭화학 기반 tPDC 당화알부민 나노플랫폼**을 동일 웹앱에 통합 배포하였다([/albumin.html](#)). 당밀도를 6.8로 정밀 설계하여 간 흡수를 회피하고 신장을 선택적으로 타겟, 급성신장손상(AKI)→만성신부전(CKD) 이행을 M1→M2 마크로파지 전환으로 차단하는 First-in-Class 접근이다. 두 플랫폼은 결합·구조 예측 도구를 공유하며 상호 링크로 연결된다.

7. 한계 및 향후 과제

- 본 도구의 pIC50 예측은 리간드 기반 QSAR로, 실제 3D 도킹·결합 자유에너지 계산을 대체하지 않는다. 향후 Mpro 구조 기반 도킹(예: AutoDock Vina) 연동으로 보강 예정.
- 비강 전달성·독성은 투명한 물성 휴리스틱이며, in vitro/in vivo 실측(점막 투과·체류·자극성)으로 대체·검증되어야 한다.
- Ridge 브라우저 모델($\rho=0.76$)은 경량화를 위한 선형 근사로, 서버 RandomForest($\rho=0.81$) 대비 정밀도가 낮다.
- 최적화 루프의 후보 공간은 현재 실측 라이브러리로 한정되며, 생성모델 기반 de novo 확장이 향후 과제다.

공통 고지: 본 산출물의 모든 수치는 공개 데이터로 학습·검증한 비임상 계산 예측값이며, 실험·독성·임상 데이터 또는 품목허가 판단을 대체하지 않는다.

부록 A. 재현 방법

- QSAR 학습: `python ml/train_qsar.py` → `ml/qsar_metrics.json`, `web/qsar_model.json`, `ml/qsar_rf.pkl`, `data/mpro_predictions.json` 생성.
- 웹 배포: `python deploy_mpro.py` → `web/` 전체를 엣지 Worker로 업로드.
- 로컬 앱: `app/실행.bat` 더블클릭(최초 1회 `venv` 구성 후 Streamlit 자동 실행).
- 검증: scaffold 5-fold GroupKFold out-of-fold 예측 기준 Spearman/R²/RMSE.